

گزارش پیشرفت پروژه درس گراف کاوی

تاریخ تحویل: ۱۴۰۴/۱۰/۱۴

درس: گراف کاوی (۴۰۴۱)

استاد: دکتر زینب ملکی

عنوان پروژه:

تحلیل توزیع درجه در دیتاست Amazon MovieLens Ecommerce Graph

اطلاعات دانشجو

نام و نام خانوادگی: عرفان هاشمی

شماره دانشجویی: ۴۰۲۰۱۹۱۳

ایمیل: hashemierfa@gmail.com

خلاصه اجرایی

در این مرحله از پروژه، تمرکز اصلی بر آماده‌سازی داده‌ها، ساخت گراف و انجام تحلیل‌های اولیه بر روی توزیع درجه بوده است. مطابق اهداف تعیین‌شده در پروپوزال، دیتاست Amazon MovieLens شامل تعاملات کاربران و آیتم‌ها دریافت و پس از مراحل پاک‌سازی، به صورت یک گراف دوبخشی (User-Item) مدل‌سازی شد. گراف نهایی شامل کاربران به عنوان یک دسته از گره‌ها و فیلم‌ها به عنوان دسته دوم است که یال‌ها نشان‌دهنده تعامل یا امتیازدهی کاربران به فیلم‌ها می‌باشند.

در ادامه، درجه هر گره محاسبه و توزیع درجه برای کاربران و آیتم‌ها به صورت جداگانه بررسی شد. نتایج اولیه نشان می‌دهد که توزیع درجه در هر دو بخش کاربران و فیلم‌ها دارای دم‌بلند (Long-Tail) بوده و رفتار نزدیک به شبکه‌های Scale-Free را از خود نشان می‌دهد. همچنین نمودارهای Degree Distribution و Log-Log Plot رسم شده‌اند که وجود تعداد کمی گره با درجه بسیار بالا و تعداد زیادی گره با درجه کم را تأیید می‌کنند. در مراحل بعدی، تمرکز بر مقایسه دقیق‌تر کاربران بسیار فعال و فیلم‌های بسیار محبوب و تفسیر نتایج در چارچوب سیستم‌های پیشنهاددهنده خواهد بود.

پیشرفت اهداف پروژه

هدف ۱: استخراج، تمیزسازی و ساخت گراف از دیتاست.

در این مرحله، دیتاست Amazon MovieLens دریافت و بررسی شد. داده‌های ناقص، تعاملات تکراری و رکوردهای نامعتبر حذف گردیدند. پس از پیش‌پردازش، گراف دوبخشی User-Item ساخته شد که در آن کاربران و فیلم‌ها به عنوان دو مجموعه مجزا از گره‌ها تعریف شدند. این گراف پایه اصلی تمامی تحلیل‌های بعدی را تشکیل می‌دهد.

هدف ۲: محاسبه درجه گره‌ها و تحلیل توزیع درجه.

برای هر گره در گراف، مقدار درجه محاسبه شد. توزیع درجه برای کاربران و فیلم‌ها به صورت جداگانه استخراج گردید. سپس هیستوگرام توزیع درجه رسم و بررسی شد. نتایج اولیه نشان می‌دهد که تعداد کمی از کاربران بسیار فعال هستند و تعداد کمی از فیلم‌ها حجم بالایی از تعاملات را دریافت کرده‌اند.

هدف ۳: بررسی Scale-Free بودن شبکه
 برای بررسی رفتار Scale-Free، نمودار Log-Log توزیع درجه رسم شد. شکل کلی نمودارها نشان‌دهنده رفتاری نزدیک به قانون توان (Power Law) است. این یافته با نتایج گزارش شده در مقالات مرتبط با شبکه‌های تجارت الکترونیک و سیستم‌های توصیه‌گر هم‌خوانی دارد.

کارهای انجام‌شده (Work Accomplished)

آماده‌سازی و تحلیل داده

- دریافت دیتاست Amazon MovieLens
- حذف داده‌های ناقص و تعاملات تکراری
- بررسی اندازه داده و ساختار اولیه شبکه

ساخت گراف

- مدل‌سازی داده‌ها به صورت گراف دوبخشی
- تعریف کاربران و فیلم‌ها به عنوان گره
- تعریف تعاملات به عنوان یال

پیاده‌سازی و تحلیل

- استفاده از زبان Python و کتابخانه NetworkX
- محاسبه درجه هر گره
- رسم نمودار Degree Distribution
- رسم نمودار Log-Log Plot

نتایج اولیه

مقدار	توضیح	معیار
User-Item	دوبخشی	نوع شبکه
Scale-Free	Long-Tail	الگوی توزیع درجه
رفتار غیر یکنواخت	کاربران فعال / فیلم‌های محبوب	گره‌های پرتراکم

چالش‌ها و راهکارها (Challenges Encountered and Resolutions)

چالش ۱: اندازه بزرگ دیتاست

مسئله: حجم بالای داده باعث افزایش زمان پردازش شد.
 راهکار: استفاده از نمونه‌گیری و اجرای آزمایش‌ها روی زیرگراف‌ها در مراحل اولیه.

چالش ۲: وجود داده‌های نویزی

مسئله: وجود تعاملات تکراری و داده‌های ناقص.
 راهکار: اعمال مراحل دقیق پاک‌سازی داده پیش از ساخت گراف.

منابع (References)

1. Newman, M. (2010). *Networks: An Introduction*. Oxford University Press.
2. Barabási, A.-L. (1999). *Emergence of Scaling in Random Networks*. Science.
3. Barabási, A.-L. (2016). *Network Science*. Cambridge University Press.
4. Yang, J., McAuley, J., & Leskovec, J. (2013). Modeling User Interaction in Online Recommendation Systems.