

Graph Mining Course Project Proposal

تاریخ ثبت: 1404/09/08

درس: گراف کاوی 4041

استاد: دکتر زینب مالکی

Student Information

نام دانشجویان: علیرضا حداد ، شایان رواخواه

شماره دانشجویی: 40121163 ، 40123703

ایمیل‌ها:

a.haddad@ec.iut.ac.ir

s.ravakhah@ec.iut.ac.ir

Project Title

Modeling Virus Propagation in Internet AS-Level Networks

Abstract

هدف این پروژه شبیه‌سازی انتشار یک ویروس فرضی در شبکه اینترنت جهانی (Autonomous System-level) است تا مشخص شود کدام بخش‌های شبکه در معرض آسیب بیشتری قرار دارند. با استفاده از دیتاست بزرگ

AS- Skitter، که شامل بیش از یک میلیون نود و ده میلیون یال است، رفتار انتشار تحت مدل

Independent Cascade با احتمال آلودگی p شبیه‌سازی می‌شود. هدف این است که بررسی کنیم اگر یک یا چند AS آلوده شوند، ویروس با چه احتمالی می‌تواند به بخش‌های وسیعی از شبکه نفوذ کند. انتظار می‌رود با تحلیل گراف و شبیه‌سازی انتشار، بتوان نودهای کلیدی و مسیرهای حساس شبکه را شناسایی کرد و تأثیر ساختار توپولوژی شبکه بر سرعت و گستردگی انتشار ویروس را بررسی نمود. این پروژه به درک بهتر آسیب‌پذیری شبکه‌ها و کاربرد گراف‌کاوی در امنیت شبکه کمک می‌کند.

Problem and Motivation

ایده‌ی اولیه این پروژه از انیمیشن *Ralph Breaks the Internet* گرفته شد. در این فیلم، ورود یک ویروس به فضای اینترنت باعث ایجاد اختلال در کل شبکه جهانی می‌شود. این مفهوم داستانی ما را به این فکر رساند که اگر چنین اتفاقی

در یک شبکه واقعی مانند ساختار AS های اینترنت رخ دهد، انتشار ویروس در دنیای واقعی چه الگو و گستره‌ای خواهد داشت.

شبکه‌های AS استخوان‌بندی اصلی اینترنت را تشکیل می‌دهند و هر AS نماینده یک ISP، سازمان، شرکت یا شبکه‌ی بزرگ است. آلودگی یک AS مانند انتشار بدافزار، Route hijack، یا حمله مبتنی بر BGP می‌تواند به اختلال گسترده در خدمات و زیرساخت‌ها منجر شود.

این پروژه به بررسی این پرسش می‌پردازد: اگر یک ویروس وارد شبکه شود، تا کدام بخش شبکه گسترش می‌یابد و چه توپولوژی‌هایی آسیب‌پذیرتر هستند؟

Objectives

- تحلیل ساختاری گراف اینترنت جهانی و استخراج ویژگی‌های آن.
- شبیه‌سازی انتشار ویروس با مدل Independent Cascade و بررسی گستردگی آلودگی.
- شناسایی نودهای کلیدی و مسیرهای حساس با استفاده از شاخص‌های centrality.
- بررسی نقش AS های پرتراфик (درجه بالا) در تشدید انتشار.

Related Work

مطالعات CAIDA درباره توپولوژی AS نشان می‌دهد که اینترنت ساختاری scale-free دارد و وجود نودهای hub می‌تواند به انتشار سریع آلودگی منجر شود. مدل Independent Cascade که توسط Kleinberg و Kempe معرفی شد، چارچوب اصلی تحلیل انتشار احتمالاتی در شبکه‌ها است. همچنین مطالعاتی مانند کار Pastor-Satorras نشان داده‌اند که شبکه‌های scale-free در برابر انتشار ویروس بسیار آسیب‌پذیرند.

Proposed Methodology

Dataset(s)

- نام: AS-Skitter
- اندازه: حدود 1.69 میلیون نود و 11 میلیون یال
- نوع: گراف بدون جهت
- پیش‌پردازش: حذف نودهای isolated و نمونه‌گیری برای شبیه‌سازی عملی

Techniques and Algorithms

- **Independent Cascade Model:** در هر مرحله نود آلوده تلاش می‌کند هر همسایه را با احتمال p آلوده کند.

- **Simulation Framework:** انجام هزاران اجرا برای محاسبه میانگین انتشار و مقایسه seed های مختلف.

- **Tools:** Matplotlib, NetworkX, Python

گام‌ها:

- خواندن دیتاست و ساخت گراف
- نمونه‌گیری یا کاهش اندازه برای شبیه‌سازی عملی
- اجرای مدل انتشار و ویروس مرحله به مرحله
- ثبت تعداد نودهای آلوده و رسم نمودار رشد آلودگی

Evaluation Plan

معیارها:

- درصد نودهای آلوده نهایی
- سرعت گسترش آلودگی
- شاخص‌های centrality

Baseline:

- انتشار تصادفی
- حذف نودهای کلیدی از گراف

Challenges and Resources

چالش اصلی اندازه بسیار بزرگ دیتاست است که اجرای مدل را سنگین می‌کند. برای حل آن از sampling یا بخش‌بندی شبکه استفاده می‌شود. همچنین مدیریت حافظه در NetworkX ممکن است مشکل‌ساز شود و نیاز به استفاده از ساختارهای کارآمدتر وجود دارد.

References

CAIDA. (2005). AS Skitter Dataset. Stanford SNAP.